Duta | Engineering Change Specification
مستند تغییرات الگوریتم‌های دسته‌بندی، امتیازدهی و خوشه‌بندی
CHG-002

مشخصات سند

نسخه	V1.0
تاریخ	1405/07/30
تیم	Duta
وضعیت	تأیید شده

تاریخچه تغییرات

تحلیلگر	عنوان یا توضیحات	تاریخ
مانی مردآزاد ناوی	اصلاح الگوریتم دسته‌بندی، فرمول امتیازدهی کلستر و رفع Race Condition	1405/07/30

عنوان تغییر

شناسه	CHG-002
عنوان	بازطراحی منطق CategoryClassifierService، ScoringService، ClusteringServiceو SlugService
لایه سیستم	Backend — Business Logic & Intelligence Services
اولویت	بحرانی(Critical)

توصیف

این سند شامل اصلاحات منطقی و ریاضی در هسته هوشمند پلتفرم Duta است که وظیفه تشخیص دسته‌بندی خبر، خوشه‌بندی اخبار مشابه با الگوریتم Jaccard و محاسبه امتیاز اعتبار چندمنبعی را بر عهده دارد.

جدول تفصیلی تغییرات و دلایل فنی

کد مورد	بخش / فایل	وضعیت قبلی (مشکل فعلی)	ریسک و مشکل در آینده	وضعیت جدید (تغییر اعمال‌شده)	دلیل فنی تصمیم‌گیری
ALG-01	CategoryClassifierService.java	استفاده از lower.contains(keyword) بدون بررسی مرز کلمات و بدون نرمال‌سازی حروف فارسی/عربی.	کلمات کوتاه داخل کلمات نامرتبط پیدا می‌شدند: «جام» در «انجام»، «جامعه»، «سرانجام» • «شنا» در «کارشناس»، «شناسایی» • «رای» در «برای»، «اجرای» • «گل» در «گلستان»، «گلوله» در نتیجه درصد بالایی از اخبار سیاسی/اجتماعی به اشتباه در دسته «ورزشی» قرار می‌گرفتند.	۱. نرمال‌سازی حروف (ي→ی، ك→ک)، نیم‌فاصله به فاصله. ۲. جداسازی پسوندهای جمع («ها»، «های»). ۳. پدینگ تیتر و کلمات کلیدی با فاصله + " " + kw + " ") جهت جستجوی دقیق مبتنی بر مرز کلمه..	حذف ۱۰۰٪ خطاهای Substring False Positive با حفظ سرعت اجرای O(1) بدون تحمیل بار Regex سنگین.
ALG-02	ScoringService.java	۱. فرمول قبلی به صورت (Source * 0.5) + (Coverage * 0.35) + (Freshness * 0.15) بود.	۱. **باگ سقوط امتیاز:** وقتی ۱ منبع با اعتبار ۹۰	بازنویسی فرمول بر پایه **کیفیت وزنی منابع (Credibilit**	تضمین یکنواختی ریاضی (Monotonicit: هرچه منابع)

		۲ .ضریب تنوع بر اساس تعداد categoryهای مختلف داخل یک کلستر حساب می‌شد!	خبری را منتشر می‌کرد امتیاز کلستر 90 (سبز) بود؛ اما وقتی منبع دوم با اعتبار ۹۰ همان خبر را تایید می‌کرد، امتیاز طبق فرمول به 72(نارنجی) سقوط می‌کرد! ۲ .چون اخبار داخل یک کلستر درباره یک موضوع واحد هستند، همگی یک category دارند و همیشه ۱۵٪ جریمه می‌شدند. ۳ .با گذشت ۲۴ ساعت، ۱۵ نمره از اعتبار خبر کم می‌شد (انگار خبر واقعی روز قبل، امروز نامعتبر شده است!).	**(y^2)**به عنوان امتیاز پایه + **پاداش تایید چندمنبعی مستقل (Verification Boost)** بر اساس تعداد منابع یکتای بالای ۷۵.	معتبر بیشتری یک خبر را پوشش دهند، امتیاز اعتبار آن افزایش می‌یابد نه کاهش.
ALG-03	ClusteringService.java وScoringService.java	شمارش تعداد کل رکوردها (articles.size())و sourceCount + 1)	اگر یک خبرگزاری واحد در طول ۲ ساعت، ۲	شمارش بر اساس شناسه یکتای منبع (distinct source.id).	اعتبار خبر تنها زمانی باید افزایش یابد که خبرگزاری‌های مستقل و

		به جای شمارش منابع یکتا.	خبر مشابه درباره یک رویداد منتشر می‌کرد، سیستم آن را «۲ منبع مستقل» حساب می‌کرد و امتیاز تایید چندمنبعی کاذب می‌داد.		متفاوت آن را تایید کرده باشند.
ALG-04	ClusteringService.java وSlugService.java	عدم وجود قفل همگام‌سازی (synchronized)در هنگام اجرای موازی ۵ ترد RSS و بریده شدن ناقص کلمات در اسلاگ ۸۰ کاراکتری.	۱ .اگر دو منبع هم‌زمان یک خبر فوری را منتشر می‌کردند، دو ترد موازی به دلیل عدم مشاهده کلستر کامیت‌نشده، دو کلستر مجزا برای یک خبر می‌ساختند. ۲ .اسلاگ فارسی از وسط کلمه قطع می‌شد.	۱ .افزودن synchronized (clusterLockدر clusterArticleو synchronizedدر generateSlug. ۲ .برش اسلاگ در آخرین خط تیره (lastIndexOf('-'))قبل از کاراکتر ۸۰.	جلوگیری از RaceConditionدر تردهای موازی rssTaskExecutorو تولید URLهای فارسی خوانا و استاندارد برای سئو.